



# 情報数学II

## 第10回 確率・統計3

---

小野順貴  
(ONO, Nobutaka)

東京都立大学 システムデザイン学部

情報科学科 教授

onono@tmu.ac.jp



# 推定問題

■ 与えられたデータから、何らかの変数(パラメータ)を推定する問題を考える。

- 例: 重心が偏ったいびつなコインがある。通常のコインのように、表、裏が出る確率を同様に確からしいとは考えられない。このコインを10回投げたところ、7回表がでた。表が出る確率を  $b$  とするとき、 $b$  をどのように推定すればよいだろうか？
- この問題であれば、 $b=7/10=0.7$  と推定するのが妥当なように思える。しかし、より複雑な問題にも適用できるような、一般的なアプローチはどうすればよいだろうか？

# 最尤法

- 観測されたデータから、確率モデルのパラメータを最も尤も(もっとも)らしい、という基準で推定する手法
- 概要

- 確率変数:  $x$  (一般には多次元ベクトル)
- 確率密度関数:  $p(x; \theta)$
- パラメータ:  $\theta$  (一般には多次元ベクトル)

とするとき、 $L(\theta; x) = p(x; \theta)$  を尤度関数という。

- 確率密度関数は、 $x$  の関数。 $x$  で積分すると1になる。
- 尤度関数は  $\theta$  の関数。 $\theta$  で積分しても1にはならない。
- 観測  $x$  に対し、以下の推定を最尤法という。

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(\theta; x)$$

$\max_{\theta} f(\theta)$  は  $f(\theta)$  の  
最大値

$\operatorname{argmax}_{\theta} f(\theta)$  は  $f(\theta)$  の  
最大値を与える  $\theta$



# 二項分布の例

- 確率  $b$  で表が出るコインを  $n$  回投げ、 $x$  回表が出る確率を考える
  - $n$ 回の中で $x$ 回表になる組み合わせ(表表裏、など):  ${}_nC_x$  通り
  - それぞれの組み合わせの確率:  $b^n(1-b)^{(n-x)}$
  - 求める確率:  ${}_nC_x b^n(1-b)^{(n-x)}$
- このとき  $b$  が、前ページのパラメータ  $\theta$  にあたる。  
(簡単のため、 $n$ は定数とする)

$$L(b; x) = p(x; b) = \underline{{}_nC_x b^x (1-b)^{(n-x)}}$$

二項分布と呼ばれる

- 最尤法で  $b$  を求めるには、与えられた  $x$  に対して、 $L(b; x)$  を最大にする  $b$  を求めればよい

# 対数尤度関数の最大化

- 二項分布に限らず多くの場合、尤度関数そのものの最大化より、その対数である対数尤度関数の最大化を考える方が容易
  - 対数関数は単調なので、 $\operatorname{argmax}_{\theta} f(\theta) = \operatorname{argmax}_{\theta} \log f(\theta)$
  - 独立な事象の確率は積で表され、対数をとることによって和になるため

- 二項分布の例:

$$\log L(b; x) = \log {}_n C_x + x \log b + (n - x) \log(1 - b)$$

- 最大値を求めるために  $b$  で微分すると

$$\frac{d \log L(b; x)}{db} = \frac{x}{b} - \frac{n - x}{1 - b}$$

- $=0$ として  $b$  について解くと

$$x(1 - b) - (n - x)b = 0 \quad \longrightarrow \quad b = \frac{x}{n}$$

直感にも  
合致した値が  
求まった



# MATLAB演習10

---

- $n = 10, x = 7$  として実際に尤度関数

$$L(b; x) = {}_n C_x b^x (1 - b)^{(n-x)}$$

の概形をMATLABで求め、数値的に最大値を求めよ。

- ${}_n C_x$  は、MATLABでは、`nchoosek(n,x)`で計算できる。
- $b$  は0から1までの値をとるので、  
適当な刻み幅(例えば0.01)をとって求めよ。



# MATLAB演習10解答例

---

```
n=10;
```

```
x=7;
```

```
b=0:0.01:1;
```

```
logL=nchoosek(n,x)*b.^x.*(1-b).^(n-x);
```

```
plot(b,logL);
```

```
xlabel('b');
```

```
ylabel('log likelihood');
```



# 正規分布の例

- データ  $x_1, \dots, x_N$  がそれぞれ独立に同一の正規分布に従うとき、正規分布のパラメータ  $\mu, \sigma^2$  を求めたい
  - 複数の確率変数が独立に同一の分布に従うことを **独立同分布** (independent and identically distributed; **i.i.d.**) という
  - 正規分布: 
$$p(x; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$
  - パラメータ:  $\theta = (\mu, \underline{\sigma^2})$   
ひとつの文字として扱う



# 正規分布の対数尤度関数

- 複数の確率変数の確率密度関数を同時確率密度関数という。
- $\boldsymbol{x} = (x_1, \dots, x_N)$  の同時確率密度関数

$$p(\boldsymbol{x}; \boldsymbol{\theta}) = \prod_{n=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_n - \mu)^2}{2\sigma^2}}$$

- $x_1, \dots, x_N$  は独立なので、同時確率密度関数はそれらの積
- $\prod$  は要素すべてを乗じることを表す記号で、総乗ともよばれる。
  - 要素すべての和(総和)を表す記号は  $\sum$
- 対数尤度関数:


$$\log L(\boldsymbol{\theta}; \boldsymbol{x}) = -\frac{N}{2} \log(2\pi) - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2$$

# 正規分布の平均、分散の最尤推定量

- パラメータが2つ(平均、分散)あるので、対数尤度関数を平均、分散で微分して0とおき連立方程式を解く。
- 対数尤度関数の微分

$$\frac{\partial \log L(\boldsymbol{\theta}; \boldsymbol{x})}{\partial \mu} = \frac{1}{\sigma^2} \sum_{n=1}^N (x_n - \mu) = 0$$

$$\frac{\partial \log L(\boldsymbol{\theta}; \boldsymbol{x})}{\partial (\sigma^2)} = -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{n=1}^N (x_n - \mu)^2 = 0$$



- 最尤推定量

$$\mu = \frac{1}{N} \sum_{n=1}^N x_n$$

標本平均に等しい

$$\sigma^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu)^2$$

標本分散に等しい



# MATLAB演習11

■  $x_1, \dots, x_N$  として、平均0、分散1の正規分布に従う標本を100個生成し(つまり  $N = 100$ )、その標本に対して対数尤度関数

$$\log L(\boldsymbol{\theta}; \boldsymbol{x}) = -\frac{N}{2} \log(2\pi) - \frac{N}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2$$

を求め、 $\sigma^2 = 1$  付近で最大値をとることを確認せよ。

ただし、対数尤度関数は  $\mu = 0$  とし、 $\sigma^2$  の関数として表せ。

また、 $\sigma^2$  の範囲は0.5~3とせよ。



# MATLAB演習11解答例

---

```
N=100;  
x=randn(1,N);  
sigma2=0.5:0.01:3;  
logL=-N/2*log(2*pi)-N/2*log(sigma2)-sum(x.^2)./(2*sigma2);  
plot(sigma2,logL);  
xlabel('sigma^2');  
ylabel('log likelihood');
```

# 不偏推定量

- 推定量も「確率変数」である

- $x = (x_1, \dots, x_N)$  が確率変数ならば、

$$\hat{\mu} = \frac{1}{N} \sum_{n=1}^N x_n \text{ も確率変数}$$

真の値と区別するため、ここではハットをつける

- 推定量の期待値が真の値に一致するとき、これを不変推定量と呼ぶ。
- 例えば標本平均は、以下より不偏推定量

$$E[\hat{\mu}] = \frac{1}{N} \sum_{n=1}^N E[x_n] = \frac{1}{N} \sum_{n=1}^N \mu = \mu$$



# 不偏分散

- 最尤推定量は必ず不偏推定量であるとは限らない
  - 標本数が増えるにつれ、漸近的に不偏に近づく(一致性)
- 正規分布の分散の最尤推定量は不偏推定量ではない

$$E[\hat{\sigma}^2] = \frac{1}{N} \sum_{n=1}^N E[(x_n - \hat{\mu})^2] = \frac{N-1}{N} \sigma^2$$

標本分散は真の分散より小さく見積もってしまう。  
導出はやや煩雑なので省略するが、真の平均  
ではなく、標本平均を用いていることが要因。

- 分散の不偏推定量


$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{n=1}^N (x_n - \hat{\mu})^2$$

# 線形回帰分析

- 1変数の線形回帰問題とは、与えられたデータ  $(x_k, y_k)$  ( $k = 1, \dots, K$ ) に対し、線形回帰式  $y = ax + b$  が最もよくフィットするようにパラメータ  $(a, b)$  を求める問題。
- フィッティングの良さとしては二乗誤差がよく用いられる。

$$f(a, b) = \sum_{k=1}^K (\underbrace{ax_k + b}_{\text{線形回帰モデル}} - \underbrace{y_k}_{\text{データ}})^2$$

モデルとデータの二乗誤差



- どうやって二乗誤差を最小にする  $(a, b)$  を求めるか？



# 最小二乗法と最尤推定

- 2つのデータ  $x = (x_1, \dots, x_N)$  と  $y = (y_1, \dots, y_N)$  の間に、

$$y_n = ax_n + b + \varepsilon_n$$

という線形関係が成り立つことを仮定する。ただし、 $\varepsilon_n$  はモデル化誤差を表し、独立に平均0、分散  $\sigma^2$  の正規分布に従うものとする。このとき、 $a, b$  を最尤法で求めるとどうなるだろうか？

- $\varepsilon_n$  が正規分布に従うのであるから、 $a, b, x_n$  が与えられた場合の  $y_n$  の確率密度関数は以下で与えられる。

$$p(y_n; a, b, x_n) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(ax_n + b - y_n)^2}{2\sigma^2}}$$



# 最小二乗法と最尤推定

- 尤度関数

$$L(a, b; \mathbf{x}, \mathbf{y}) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \prod_{n=1}^N e^{-\frac{(ax_n + b - y_n)^2}{2\sigma^2}}$$


- 対数尤度関数

$$\log L(a, b; \mathbf{x}, \mathbf{y}) = \underbrace{-\frac{N}{2} \log(2\pi) - \frac{N}{2} \log \sigma^2}_{a, b \text{ に依らない定数項}} - \underbrace{\frac{1}{2\sigma^2} \sum_{n=1}^N (ax_n + b - y_n)^2}_{a, b \text{ に依らない係数} \quad \text{二乗誤差}}$$


二乗誤差の最小化は、モデル化誤差に正規分布を仮定した最尤推定と等価

# 外れ値に対する影響

- 最小二乗法は外れ値に弱いことが知られている。



外れ値ひとつで  
推定結果が大きく  
変わってしまう



- なぜか？前ページから、最小二乗法は、モデル化誤差に正規分布を仮定して最尤推定していることと等価。しかし、正規分布からは外れ値は極めて稀にしか発生しない。このミスマッチが原因。

# 外れ値に対する影響の緩和

- もし、データに外れ値が含まれており、正規分布の仮定が適切でない場合には、モデル化誤差に異なる分布を考えることにより、外れ値に頑健な推定が行える。
- 例) モデル化誤差がラプラス分布に従うと仮定すると

$$p(y_n; a, b, x_n) = \frac{1}{\sqrt{2}\sigma} e^{-\frac{|ax_n + b - y_n|}{\sigma/\sqrt{2}}}$$

$$\rightarrow f(a, b) = \sum_{k=1}^K |ax_k + b - y_k|$$

最尤推定は絶対値誤差最小化に等価



# まとめ

---

## ■ 最尤法

- 尤度関数を最大化するという基準でパラメータを推定する枠組み
- 最小二乗法は、誤差に正規分布を仮定した最尤推定と解釈できる